

Cahier d'expériences

Exploration de la notion de méta-apprentissage

*Dans quelle mesure un système apprenant peut
prendre conscience de ses performances et altérer son
comportement ?*

Yann Boniface, Alain Dutech, Nicolas Rougier
Matthieu Zimmer

30 mai 2012

Table des matières

Table de matière	2
Expérience A1	3
Expérience A2	8
Expérience A3	13
Expérience A4	18
Expérience B1	22
Expérience B3	26
Expérience C1	30
Expérience C2	34
Expérience C3	38
Expérience C4	42
Expérience D1	45
Expérience D2	49
Expérience D3	53
Expérience D4	57

Expérience A1

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires Discretisation de la couche cachée du premier réseau




Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.


Secondaires Représentations au travers des poids du premier réseau

**Notes**

- plus une case est noire, plus sa présence est importante pour le chiffre en question
- plus une case est blanche, plus son absence est importante

Conclusion Il est assez difficile d’y distinguer les chiffres, mais cela semble suffisant pour le réseau qui a un taux de reconnaissance de 100%.

Secondaires Prototypes à l’intérieur de la première partie de la couche de sortie du second réseau



Notes

—

Conclusion Le peu d'entrées permet l'apprentissage par-coeur de chaque forme.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience A2

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseaux
- taux d'apprentissage : 0.1 sur les 2 réseaux
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances



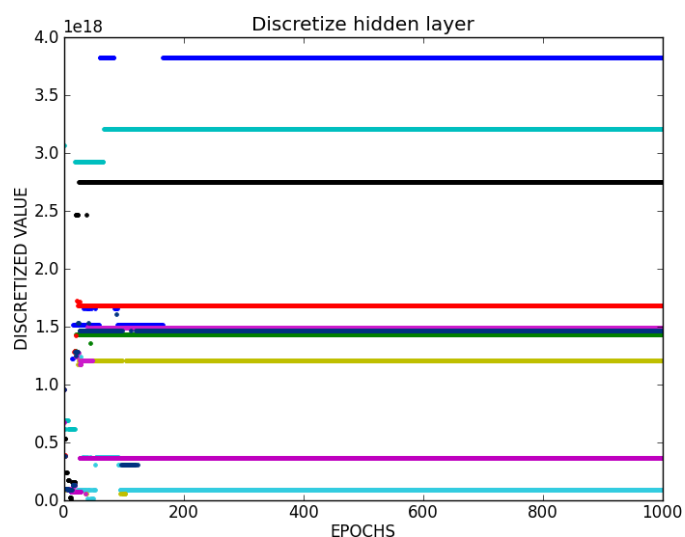

Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires Discretisation de la couche cachée du premier réseau



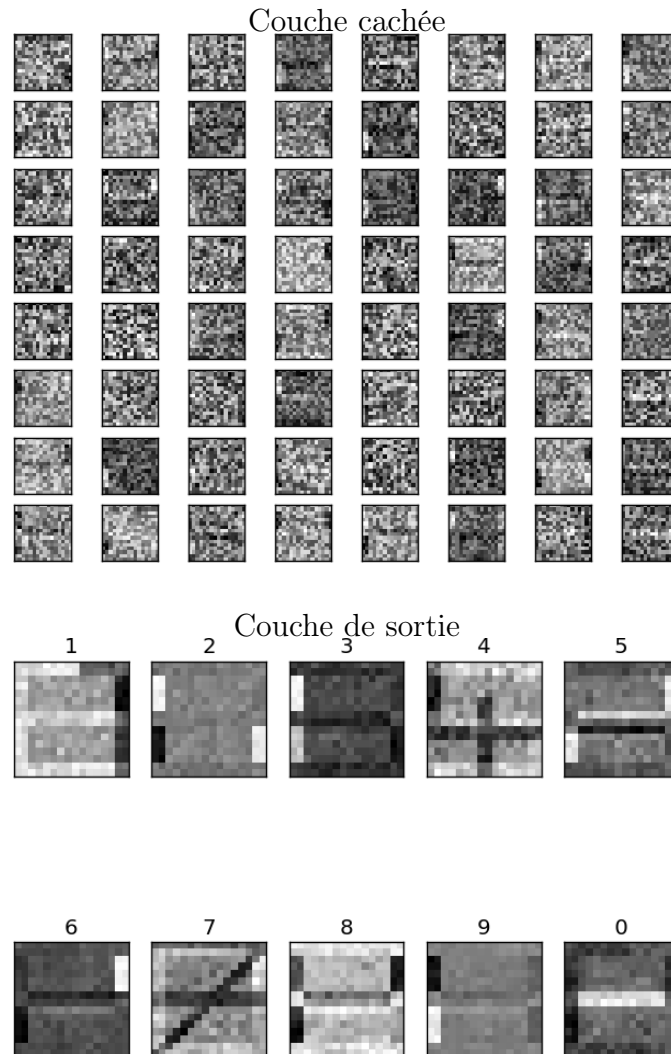
Notes

- une couleur équivaut à un chiffre présenté

- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Secondaires Représentations au travers des poids du premier réseau




Notes

- plus une case est noire, plus sa présence est importante pour le chiffre en question
- plus une case est blanche, plus son absence est importante

Conclusion Il est assez difficile d’y distinguer les chiffres, mais cela semble suffisant pour le réseau qui a un taux de reconnaissance de 100%.

Secondaires Prototypes à l’intérieur de la première partie de la couche de sortie du second réseau



Notes

—

Conclusion Le peu d'entrées permet l'apprentissage par-cœur de chaque forme.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}, \forall e' \in epochs)}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience A3

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires Discretisation de la couche cachée du premier réseau




Notes

- une couleur équivaut à un chiffre présenté

- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Secondaires Représentations au travers des poids du premier réseau




Notes

- plus une case est noire, plus sa présence est importante pour le chiffre en question
- plus une case est blanche, plus son absence est importante

Conclusion Il est assez difficile d’y distinguer les chiffres, mais cela semble suffisant pour le réseau qui a un taux de reconnaissance de 100%.

Secondaires Prototypes à l’intérieur de la première partie de la couche de sortie du second réseau



Notes

—

Conclusion Le peu d'entrées permet l'apprentissage par-coeur de chaque forme.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience A4

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires Discretisation de la couche cachée du premier réseau



Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d'avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion Le peu d'entrées permet l'apprentissage par-cœur de chaque forme.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. doi :10.1016/j.neunet.2007.09.011.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience B1

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS

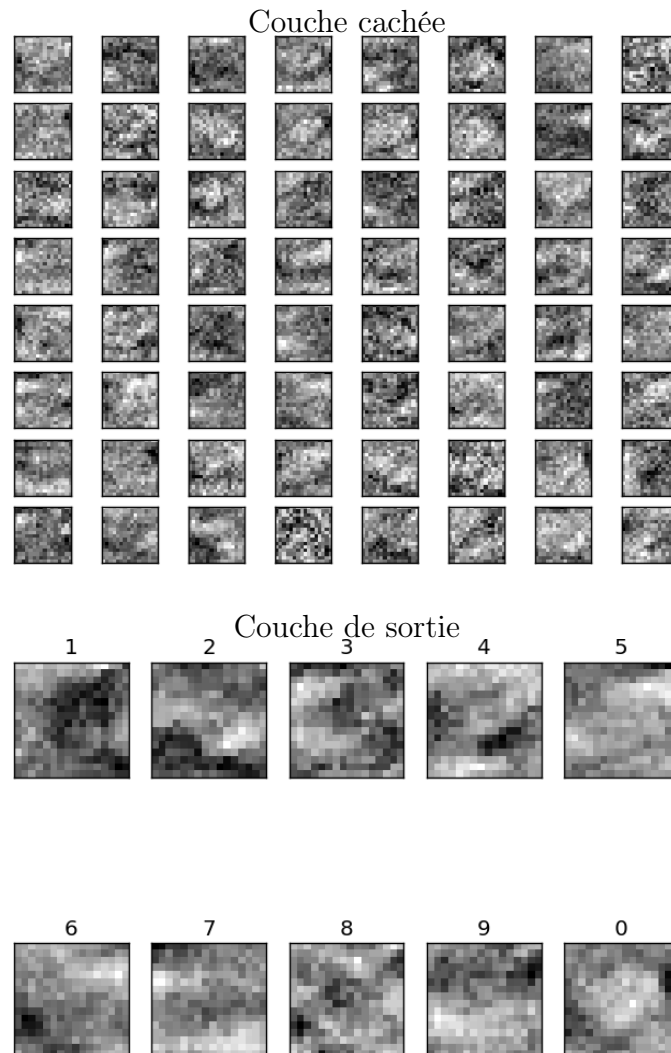


Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Secondaires Représentations au travers des poids du premier réseau



Notes

- plus une case est noire, plus sa présence est importante pour le chiffre en question
- plus une case est blanche, plus son absence est importante

Conclusion Il est assez difficile d’y distinguer les chiffres, mais cela semble suffisant pour le réseau qui a un taux de reconnaissance de 100%.

Conclusion Le peu d’entrées permet l’apprentissage par-cœur de chaque forme.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience B3

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseaux
- taux d'apprentissage : 0.1 sur les 2 réseaux
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (épisodes)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



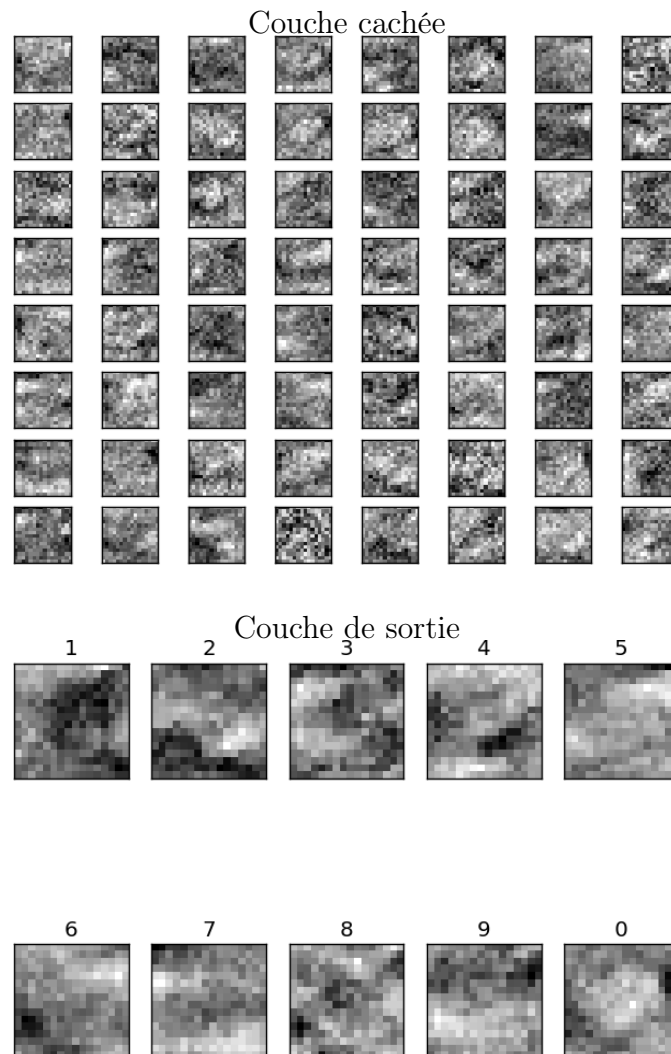
Notes

- une couleur équivaut à un chiffre présenté

- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Secondaires Représentations au travers des poids du premier réseau



Notes

- plus une case est noire, plus sa présence est importante pour le chiffre en question
- plus une case est blanche, plus son absence est importante

Conclusion Il est assez difficile d’y distinguer les chiffres, mais cela semble suffisant pour le réseau qui a un taux de reconnaissance de 100%.

Conclusion Le peu d’entrées permet l’apprentissage par-coeur de chaque forme.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}, \forall e' \in epochs)}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience C1

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté

- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience C2

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.

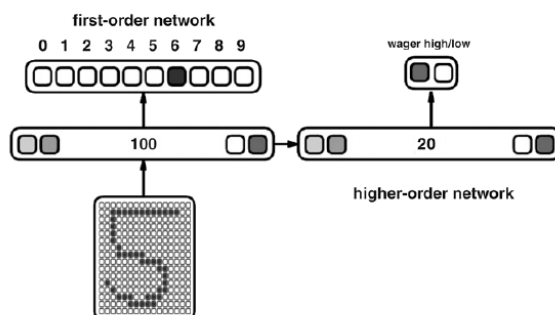
Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma




Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté

- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}, \forall e' \in epochs)}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience C3

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma





Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté

- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience C4

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma




Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances



Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience D1

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.

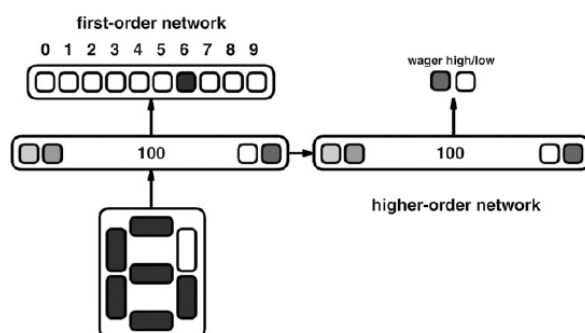
Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma




Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience D2

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.

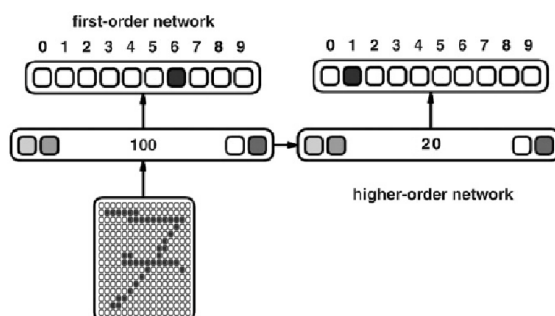
Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma




Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (époques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}, \forall e' \in epochs)}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$


References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. doi :10.1016/j.neunet.2007.09.011.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.

Expérience D4

Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article Cleeremans Alex (2007).

But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


Architecture

Description Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

Schéma




Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (épouques)
- utilisation de biais
- poids initialisés sur $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

Résultats

Principaux Analyse des performances





Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

Secondaires RMS



Notes

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

Conclusion Les neurones se stabilisent très rapidement (autour de la 50^{ième} époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.

Conclusion

Formules

RMS Pour une époque e :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

Discrétisation Pour la couche cachée *hiddenNeuron* de n neurones, un neurone pouvant être encodé par *number_cutting* valeurs différentes :

$$\sum_{i=0}^n number_cutting^i \times cutting(hiddenNeuron[i])$$

Exemple $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

Descente de gradient Touzet (1992)

Construction de l'erreur :

$$y_i = f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie}$$

$$y_i = f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

References

Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.