

# Cahier d'expériences

Exploration de la notion de méta-apprentissage

*Dans quelle mesure un système apprenant peut  
prendre conscience de ses performances et altérer son  
comportement ?*

Yann Boniface, Alain Dutech, Nicolas Rougier  
Matthieu Zimmer

30 mai 2012

## Plan

**Table des matières**

# Expérience A1

## Résumé

Reproduction et approfondissement des résultats de la première expérience 1 dans l'article [Cleeremans Alex, 2007].

## But

Comprendre de quelles manières peuvent émerger des représentations et méta-représentations dans un réseau de neurone connexionniste, en particulier sur des perceptrons multicouches.


## Architecture

**Description** Un premier réseau de perceptron multicouche apprend à discrétiser des chiffres représentés par 20 neurones d'entrées. Il est composé d'une couche cachée de 5 neurones.

Un second réseau de perceptron multicouche apprend à dupliquer toutes les couches du premier réseau en n'ayant que sa couche cachée en entrée.

L'apprentissage du second réseau, n'affecte pas les poids entre la couche d'entrée et la couche cachée du premier réseau.

## Schéma





## Paramètres

- momentum : 0.9 sur les 2 réseau
- taux d'apprentissage : 0.1 sur les 2 réseau
- 10 chiffres différents présentés
- apprentissage 10 (formes) x 1000 (épouques)
- utilisation de biais
- poids initialisés sur  $[-0.25 ; 0.25]$
- taux d'apprentissage constant
- entrées valent 0 ou 1
- sigmoïde à température 1

## Résultats

### Principaux Analyse des performances





### Notes

- les courbes SoN layer représentent les erreurs (du second réseaux) des couches du premier à reproduire
- la courbe RMS verte (SoN) est la somme des 3 courbes SoN layer

### Conclusion

- la couche cachée et la couche de sortie ne posent aucun problèmes d'apprentissage
- les performances du second réseau dépendent principalement de sa capacité à reproduire les entrées
- le second réseau apprend plus rapidement que le premier

### Secondaires Discretisation de la couche cachée du premier réseau




**Notes**

- une couleur équivaut à un chiffre présenté
- une valeur discretisée correspond à un certain encodage de la couche cachée (cf Algorithmes)

**Conclusion** Les neurones se stabilisent très rapidement (autour de la 50<sup>ième</sup> époque en moyenne), le tout permettant au second réseau d’avoir des entrées très peu variables, favorisant son apprentissage.


**Secondaires** Représentations au travers des poids du premier réseau

**Notes**

- plus une case est noire, plus sa présence est importante pour le chiffre en question
- plus une case est blanche, plus son absence est importante

**Conclusion** Il est assez difficile d’y distinguer les chiffres, mais cela semble suffisant pour le réseau qui a un taux de reconnaissance de 100%.

**Secondaires** Prototypes à l’intérieur de la première partie de la couche de sortie du second réseau



### Notes

—

**Conclusion** Le peu d'entrées permet l'apprentissage par-coeur de chaque forme.

### Conclusion

## Formules

**RMS** Pour une époque  $e$  :

$$rms\ proportion_e = \frac{rms_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (o_{i,e} - d_i)^2}}{\max(rms_{e'}), \forall e' \in epochs}$$

with  $\begin{cases} n : \text{number of neurons on the output layer} \\ o_{i,e} : \text{value obtained for the } i^{th} \text{ neuron at the } e^{th} \text{ epoch} \\ d_i : \text{value desired for the } i^{th} \text{ neuron} \end{cases}$

**Discrétisation** Pour la couche cachée *hiddenNeuron* de  $n$  neurones, un neurone pouvant être encodé par *number\_cutting* valeurs différentes :

$$\sum_{i=0}^n number\_cutting^i \times cutting(hiddenNeuron[i])$$

**Exemple**  $400 \leftarrow [0 ; 0, 25] [0 ; 0, 25] [0, 25 ; 0, 5] [0, 5 ; 0, 75] [0, 25 ; 0, 5]$   
 $400 \leftarrow 0 \times 4^0 + 0 \times 4^1 + 1 \times 4^2 + 2 \times 4^3 + 1 \times 4^4$

**Descente de gradient** [Touzet, 1992]

Construction de l'erreur :

$$\begin{aligned} y_i &= f'(a_i) \times (d_i - x_i) \text{ si } i \text{ neurone de sortie} \\ y_i &= f'(a_i) \times \sum_k (w_{ki} \times y_k) \text{ si } i \text{ neurone cache} \end{aligned}$$

Mise à jour des poids :

$$w_{ij}(t+1) = w_{ij}(t) + learning\_rate \times y_i \times x_j + momentum \times (w_{ij}(t) - w_{ij}(t-1))$$

Variables :

$$\begin{cases} f : \text{fonction sigmoïde} \\ x_i : \text{valeur du neurone } i \\ d_i : \text{valeur desirée pour le neurone } i \\ a_i : \text{somme pondérée des poids du neurone } i \end{cases}$$

## Références

[Cleeremans Alex, 2007] Cleeremans Alex, Timmermans Bert, P. A. (2007). Consciousness and metarepresentation : A computational sketch. *doi :10.1016/j.neunet.2007.09.011*.

[Touzet, 1992] Touzet, C. (1992). Les réseaux de neurones artificiels - introduction au connexionnisme.